



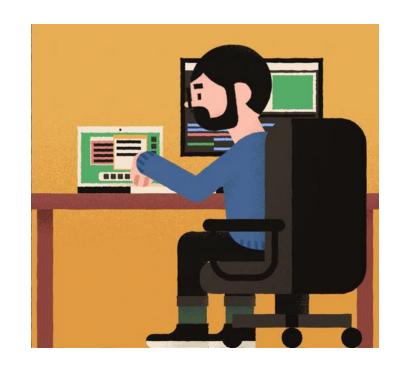
Procesamiento de datos {dplyr}

José Luis Texcalac Sangrador

Procesamiento y visualización de datos espaciales en R

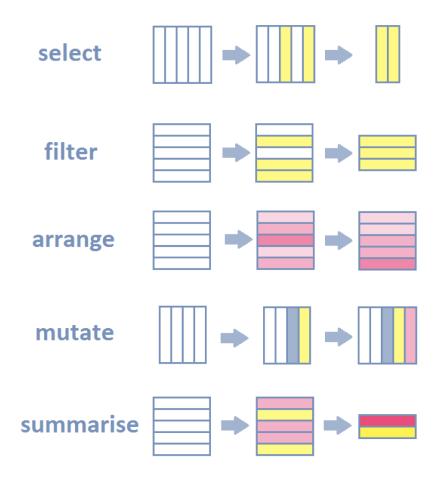


Procesamiento de datos





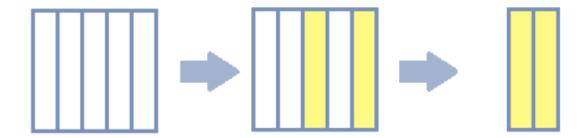
{dplyr} manipulación datos





select()

select



Generamos malla de trabajo para la sesión

```
aire_tbl <- as_tibble(airquality) %>% print()
```

```
# A tibble: 153 × 6
  Ozone Solar.R Wind Temp Month
                             Day
  190
              7.4
    41
                    67
    36
          118
              8
                    72
         149 12.6
          313 11.5
         NA 14.3
                    56
         NA 14.9
          299
              8.6
8
          99 13.8
                    59
          19
              20.1
                    61
          194
              8.6
                              10
# i 143 more rows
# i Use `print(n = ...)` to see more rows
```



```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
   <int>
            190
                  7.4
                         67
     41
                  8
            118
                         72
            149 12.6
            313 11.5
             NA 14.3
             NA 14.9
                  8.6
            299
             99 13.8
                 20.1
            194
                  8.6
                                     10
    143 more rows
   Use `print(n = ...)` to see more rows
```

Seleccionar columnas: select()

```
malla %>% select(...)

dataset

Argumentos de selección
```

Seleccionar columnas específicas

```
aire_tbl %>% select(Day, Month, Ozone)
```

```
# A tibble: 153 × 3
     Day Month Ozone
   <int> <int> <int>
                  41
                  36
                  12
                  18
                  NA
                  28
                  23
 8
                  19
 9
                   8
                  NA
   143 more rows
# i Use `print(n = ...)` to see more rows
```



```
# A tibble: 153 × 6
  Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
  <int>
            190
                  7.4
                        67
     41
            118
                  8
                        72
            149 12.6
            313 11.5
             NA 14.3
             NA 14.9
                 8.6
            299
             99 13.8
                20.1
            194
                  8.6
                                    10
   143 more rows
   Use `print(n = ...)` to see more rows
```

Seleccionar columnas: select()

```
malla %>% select(...)

dataset

Argumentos de selección
```

Seleccionar un rango de columnas

```
aire_tbl %>% select(Temp:Day)
```



```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
   <int>
            190
                  7.4
                         67
     41
                  8
            118
                         72
            149 12.6
     12
            313 11.5
             NA 14.3
             NA 14.9
                  8.6
            299
             99 13.8
                 20.1
            194
                  8.6
                                     10
    143 more rows
   Use `print(n = ...)` to see more rows
```

Seleccionar columnas: select()

```
malla %>% select(...)

dataset

Argumentos de selección
```

Seleccionar columnas a excluir

```
aire_tbl %>% select(-c(Temp, Wind))
```

```
# A tibble: 153 × 4
   Ozone Solar R Month
                         Dav
   <int>
           <int> <int> <int>
             190
      41
      36
             118
      12
             149
             313
             299
      19
 9
              19
                          10
             194
    143 more rows
# i Use `print(n = ...)` to see more rows
```



Seleccionar columnas: select()

malla %>% select(...)

dataset

Argumentos de selección

starts_with: Comienzan con este texto

ends_with: Terminan con este texto

contains: Contienen este texto

matches: Coinciden con esta expresión regular

num_range: Están en estas posiciones

one_of: Alguna de estas

everything: Todas

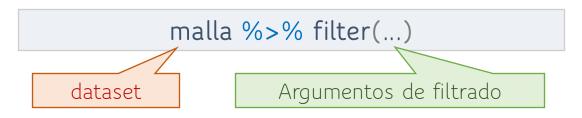


filter()

filter







x < y	menor qué	
x > y	mayor qué	
x == y	igual a	
x <= y	menor o igual a	
x >= y	mayor o igual a	
x != y	diferente de	
x %in% y	pertenece a	
is.na(x)	is NA	
!is.na(x)	Distinto de NA	



```
> aire_tbl
```

```
# A tibble: 153 × 6
  Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
   <int>
            190
                 7.4
                         67
     41
            118
                  8
      36
            149 12.6
            313 11.5
             NA 14.3
            NA 14.9
                 8.6
            299
             99 13.8
             19 20.1
            194
                  8.6
                                    10
    143 more rows
   Use `print(n = ...)` to see more rows
```

```
malla %>% filter(...)

dataset

Argumentos de filtrado
```

Filtro temperatura por arriba de 77

```
aire_tbl %>% filter(Temp > 77)
```

```
# A tibble: 85 × 6
   Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
   <int>
     45
            252 14.9
                                     29
    115
            223
                  5.7
                                     30
            286
                 8.6
            186
                  9.2
            220
                  8.6
            264 14.3
            127
                  9.7
            273
                  6.9
            291 13.8
 9
            323 11.5
                                     10
# i 75 more rows
# i Use `print(n = ...)` to see more rows
```



```
> aire_tbl
```

```
# A tibble: 153 × 6
  Ozone Solar.R Wind Temp Month
  <int>
          <int> <dbl> <int> <int> <int>
     41
           190
                7.4
                        67
                                    1
           118
                 8
     36
           149 12.6
            313 11.5
            NA 14.3
           NA 14.9
           299 8.6
         99 13.8
            19 20.1
            194
                 8.6
                                   10
   143 more rows
# i Use `print(n = ...)` to see more rows
```

```
malla %>% filter(...)

dataset

Argumentos de filtrado
```

Filtro temperatura por arriba de 77 y mes 5

```
aire_tbl %>% filter(Temp > 77 & Month == 5)
```



```
> aire_tbl
```

```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
   <int>
                 7.4
            190
                         67
      41
            118
                  8
      36
            149 12.6
            313 11.5
             NA 14.3
             NA 14.9
                  8.6
            299
             99 13.8
             19 20.1
                  8.6
                                    10
            194
    143 more rows
   Use `print(n = ...)` to see more rows
```

```
malla %>% filter(...)

dataset

Argumentos de filtrado
```

Filtro valores de Ozono distintos de NA

```
aire_tbl %>% filter(!is.na(Ozone))

# A tibble: 116 × 6
```

```
Ozone Solar.R Wind Temp Month
                                  Day
 <int>
         <int> <dbl> <int> <int> <int>
    41
           190
                7.4
                        67
           118
                 8
           149
               12.6
           313 11.5
            NA 14.9
           299 8.6
            99 13.8
                20.1
8
            NA
                6.9
                                    11
           256
                 9.7
                        69
                                    12
  106 more rows
i Use `print(n = ...)` to see more rows
```



```
> aire_tbl
```

```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
                                    Day
           <int> <dbl> <int> <int> <int>
   <int>
            190
                  7.4
      41
                          67
                                5
                                      1
            118
                   8
                         72
      36
            149 12.6
            313 11.5
      18
             NA 14.3
             NA 14.9
                          66
                  8.6
             299
             99 13.8
                 20.1
             19
                          61
             194
                  8.6
                                     10
                          69
    143 more rows
    Use `print(n = ...)` to see more rows
```

```
malla %>% filter(...)

dataset

Argumentos de filtrado
```

Filtro valores por arriba del promedio de Temp y que sean de los días 2, 7 o 11

```
aire_tbl %>% filter(Temp > mean(Temp) & Day %in% c(2, 7,11))
```

```
Ozone Solar.R Wind Temp Month
                                     Day
  <int>
         <int> <dbl> <int> <int> <int>
      29
             127
                   9.7
                          82
             259
                 10.9
                                      11
             248
                  9.2
                                       2
      49
             276
                   5.1
             139
                  8.6
                                      11
                 13.8
             255
     122
                   4
8
             137
                 11.5
                          86
                                      11
     NA
9
      78
             197
                   5.1
                          92
             252
                 10.9
10
                  14.9
                                      11
             236
                          81
```

A tibble: 11 × 6



mutate()

mutate





```
# A tibble: 153 × 6
   Ozone Solar.R Wind
                       Temp Month
           <int> <dbl> <int> <int> <int>
   <int>
                  7.4
            190
                         67
      41
                                      1
            118
                   8
      36
            149 12.6
            313 11.5
             NA 14.3
             NA 14.9
                  8.6
             299
             99 13.8
                 20.1
             19
             194
                  8.6
                                     10
    143 more rows
    Use `print(n = ...)` to see more rows
```

Generar variables: mutate()

```
malla %>% mutate(...)

dataset

Argumentos de creación de variables
```

Genero columna con el logaritmo de Ozono

A tibble: 153 × 7

```
aire_tbl %>% mutate(o3_log = log(Ozone))
```

```
Ozone Solar.R Wind Temp Month
                                  Day o3_log
        <int> <dbl> <int> <int> <int>
                                       <dbl>
<int>
  41
          190
               7.4
                       67
                                        3.71
          118
                       72
                                        3.58
          149
              12.6
                       74
                                        2.48
          313 11.5
                                        2.89
          NA 14.3
                                       NA
          NA 14.9
                                        3.33
          299
               8.6
                                        3.14
  19
          99
               13.8
                                       2.94
               20.1
                                        2.08
          19
  NA
          194
               8.6
                       69
                                   10 NA
 143 more rows
 Use `print(n = ...)` to see more rows
```



```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
   <int>
                  7.4
            190
                         67
      41
            118
                   8
      36
            149 12.6
            313 11.5
             NA 14.3
             NA 14.9
                  8.6
            299
             99 13.8
             19 20.1
            194
                  8.6
                                     10
    143 more rows
    Use `print(n = ...)` to see more rows
```

Generar variables: mutate()

```
malla %>% mutate(...)

dataset

Argumentos de creación de variables
```

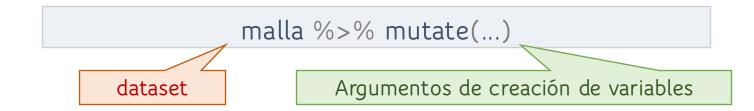
Genero copia de columna Month

```
aire_tbl %>% mutate(mes = Month)
# A tibble: 153 × 7
  Ozone Solar.R Wind Temp Month
                                    Day
                                         mes
          <int> <dbl> <int> <int> <int> <int>
  <int>
     41
            190
                  7.4
                         67
                                            5
            118
                  8
            149
                 12.6
            313 11.5
             NA 14.3
                 14.9
            299
                  8.6
                 13.8
 8
                         59
     19
 9
                 20.1
                         61
            194
                  8.6
                         69
                                     10
   143 more rows
   Use `print(n = ...)` to see more rows
```



```
# A tibble: 153 × 6
  Ozone Solar.R Wind Temp Month
                                    Day
          <int> <dbl> <int> <int> <int>
  <int>
                 7.4
     41
            190
                         67
            118
                  8
     36
            149 12.6
            313 11.5
             NA 14.3
             NA 14.9
                  8.6
            299
             99 13.8
             19 20.1
                  8.6
                                     10
            194
                         69
    143 more rows
   Use `print(n = ...)` to see more rows
```

Generar variables: mutate()



Genero nueva columna que concatena Month y Day

```
aire_tbl %>% mutate(dia_mes = str_c(Day, Month, sep = "-"))
# A tibble: 153 × 7
   Ozone Solar.R Wind Temp Month
                                    Day dia mes
           <int> <dbl> <int> <int> <int> <chr>
   <int>
                  7.4
      41
            190
                         67
                                      1 1-5
            118
                         72
                                      2 2-5
      36
                                      3 3-5
      12
            149
                 12.6
             313 11.5
                                      4 4-5
      18
             NA 14.3
                                      5 5-5
      28
                 14.9
                                      6 6-5
             299
                  8.6
                                      7 7-5
                 13.8
                                      8 8-5
      19
              19
                 20.1
                                      9 9-5
             194
                  8.6
                          69
                                     10 10-5
    143 more rows
```

i Use `print(n = ...)` to see more rows



Su turno...

- Queremos una malla de datos que contenga sólo a las columnas Day, Month, Ozone y Solar.R
- Queremos aquellos días en los que la concentración de ozono excedió o fue igual al promedio del periodo
- Queremos que los datos sean sólo del mes 7
- Requerimos transformar a logarítmica la variable de ozono
- No guarde el resultado, sólo genere la consulta



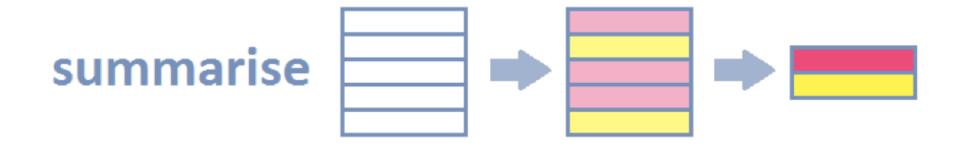


```
aire_tbl %>%
  select(Day, Month, Ozone, Solar.R) %>%
  filter(Ozone >= mean(Ozone, na.rm = TRUE) & Month != 7) %>%
  mutate(o3_lag = log(Ozone))
```

```
# A tibble: 26 × 5
    Day Month Ozone Solar.R o3_lag
  <int> <int> <int>
                   <int> <dbl>
     29
                45
                      252
                            3.81
     30
           5 115
                      223 4.74
           6 71
                      291 4.26
           8 78
                       NA 4.36
           8 66
                          4.19
                       NA
           8 122
                      255
                            4.80
              89
                      229
                            4.49
           8 110
                      207
                            4.70
     12
                44
                      192
                            3.78
     14
                65
                      157
                            4.17
# i 16 more rows
# i Use `print(n = ...)` to see more rows
```



summarise()





```
aire_tbl %>%
    summarise(
        media_ozono = mean(Ozone),
        media_temp = mean(Temp)
)
```

summarise()

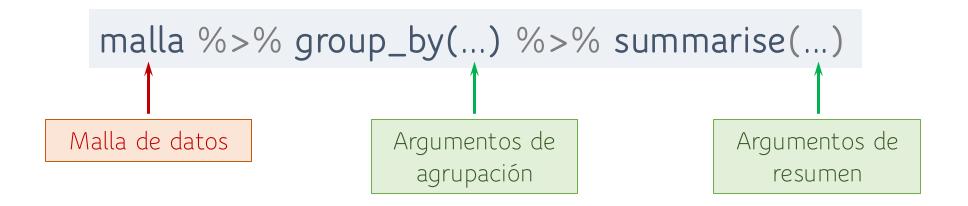
Obtenemos una medida de resumen de cada una de las variables que especifiquemos



```
aire_tbl %>%
    summarise(
        media_ozono = mean(Ozone, na.rm = TRUE),
        media_temp = mean(Temp)
)
```



Agrupar datos: group_by()





Agrupar datos... group_by()

malla

%>% group_by(entidad) %>% summarise(...)

entidad

pob_pro pob_to

entidad	municipio	población
Aguascalientes	Asientos	51,536
Aguascalientes	Calvillo	58.250
Baja California	Ensenada	443,807
Baja California	Mexicali	1,049,792
Ciudad de México	Azcapotzalco	432,205
Ciudad de México	Benito Juárez	434,153

Hguascallentes	HSIENTOS	51,536
Aguascalientes	Calvillo	58,250

Baja California	Ensenada	443,807
Baja California	Mexicali	1,049,792

Aguascalientes	54,893.0	109,786
Baja California	433,179.0	1,493,599
Ciudad de México	740,998.5	866,358

Ciudad de México	Azcapotzalco	432,205
Ciudad de México	Benito Ju á rez	434,153

malla %>%
group_by(entidad) %>%
summarise(pob_prom = mean(población),
pob_tot = sum(población),
n = n())



```
aire_tbl %>%
  group_by(Month) %>%
  summarise(
    media_ozono = mean(Ozone, na.rm = TRUE),
    media_temp = mean(Temp)
)
```

```
# A tibble: 5 \times 3
 Month media_ozono media_temp
 <int>
           <dbl>
                      <dbl>
             23.6
                 65.5
             29.4
                      79.1
             59.1
                      83.9
             60.0
                  84.0
     9
             31.4
                      76.9
```



```
aire_tbl %>%
  group_by(Month) %>%
  summarise(
    media_ozono = mean(Ozone, na.rm = TRUE),
    media_temp = mean(Temp),
    tot_datos = n(),
    tot_na_o3 = sum(!is.na(Ozone)),
    porcent_mes_o3 = (tot_na_o3 * 100)/tot_datos
)
```

```
# A tibble: 5 \times 6
 Month media_ozono media_temp tot_datos tot_na_o3 porcent_mes_o3
            <dbl>
                      <dbl>
 <int>
                              <int>
                                       <int>
                                                    <dbl>
             23.6
                      65.5
                                          26
                                 31
                                                     83.9
             29.4
     6
                      79.1
                                 30
                                                     30
             59.1
                      83.9
                                 31
                                          26
                                                     83.9
     8
             60.0
                      84.0
                                          26
                                                     83.9
                                 31
```

30

29

96.7

76.9

31.4



En ocasiones requerimos identificar los valores únicos de una variable

aire_tbl %>% distinct(Month)

```
# A tibble: 5 × 1

Month
<int>
1     5
2     6
3     7
4     8
5     9
```



Esta función la utilizamos para ordenar los valores de una variable.

aire_tbl %>% arrange(Solar.R)

```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
                                     Day
          <int> <dbl> <int> <int> <int>
   <int>
      16
                   6.9
                                      21
                   9.7
                                      21
                                      28
                   9.2
                                      22
                 20.1
             20 16.6
                                      25
             24 13.8
                 10.9
                                      14
                   9.7
                                      23
              27 10.3
                          76
                                      18
    143 more rows
# i Use `print(n = ...)` to see more rows
```



Esta función la utilizamos para ordenar los valores de una variable.

```
aire_tbl %>%
    distinct(Month) %>%
    arrange(desc(Month))
```

```
# A tibble: 5 × 1
   Month
      <int>
1      9
2      8
3      7
4      6
5      5
```



relocate()

Esta función la utilizamos para mover una columna a otra posición.

```
# A tibble: 153 × 6
   Ozone Solar.R Wind Temp Month
                                    Day
          <int> <dbl> <int> <int> <int>
   <int>
      41
            190
                  7.4
                         67
            118
                 12.6
            149
            313
                 11.5
           NA 14.3
                 14.9
            299
                  8.6
                          65
                 13.8
                          59
             19
                 20.1
             194
                   8.6
                          69
                                      10
    143 more rows
    Use `print(n = ...)` to see more rows
```

aire_tbl %>%
relocate(Day, Month, .before = Ozone)

```
# A tibble: 153 × 6
     Day Month Ozone Solar.R Wind Temp
                     <int> <dbl> <int>
   <int> <int> <int>
                         190
                              7.4
                                      67
                        118
                              8
                                      72
                         149 12.6
                                      74
                  12
                  18
                         313
                             11.5
                                      62
                         NA 14.3
                                      56
                         NA 14.9
                                      66
                         299
                              8.6
                                      65
                                      59
                             13.8
                             20.1
                                      61
                         194
                              8.6
                                      69
    143 more rows
   Use print(n = ...) to see more rows
```



relocate()

Esta función la utilizamos para mover una columna a otra posición.

```
# A tibble: 153 × 6
  Ozone Solar.R Wind Temp Month
          <int> <dbl> <int> <int> <int>
  <int>
     41
            190
                 7.4
                         67
     36
            118
                         72
                12.6
            149
            313 11.5
          NA 14.3
           NA 14.9
            299
                  8.6
                 13.8
                 20.1
            194
                  8.6
                                    10
    143 more rows
    Use `print(n = ...)` to see more rows
```

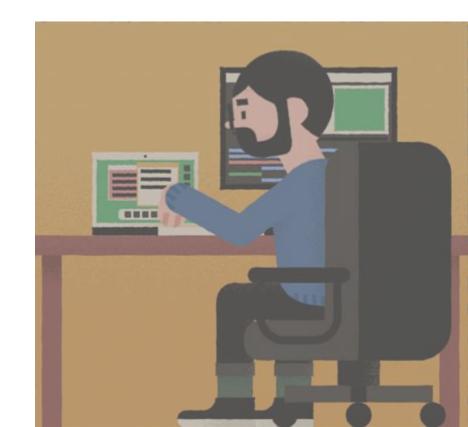
```
aire_tbl %>%
    relocate(Temp, .after = Ozone)
```

```
# A tibble: 153 × 6
   Ozone Temp Solar.R Wind Month
                <int> <dbl> <int> <int>
   <int> <int>
     41
                  190
                       7.4
           67
     36
                  118
                  149 12.6
                  313 11.5
                  NA 14.3
                   NA 14.9
                        8.6
                      13.8
                       20.1
                        8.6
                                     10
                  194
   143 more rows
# i Use `print(n = ...)` to see more rows
```



Su turno...

- Importe a su sesión el archivo red_manual_particulas_susp.csv y nombre al objeto como redma
- ¿qué parámetros se miden?
- ¿cuál es la fecha más antigüa y más reciente de la malla?
- ¿qué estación o estaciones tienen la concentración más baja de PM_{10} ?





¿qué parámetros se miden?

```
aire_tbl %>%
    distinct(id_parameter)
```

```
# A tibble: 3 × 1
id_parameter
<chr><</pre>
```

- 1 PM10
- 2 PST
- 3 PM25



Fecha más antigua de la malla

```
summary(aire_tbl$id_parameter)
```

> summary(redma\$date)

```
Min. 1st Qu. Median Mean 3rd Qu. Max. "1989-01-02" "1997-03-27" "2006-05-29" "2006-06-23" "2015-06-05" "2024-12-26"
```



Concentración más baja de PM₁₀

```
aire_tbl %>%
  filter(id_parameter == "PM10") %>%
  arrange(value)
```

```
# A tibble: 19,927 × 5
          id_station value id_parameter unit
  date
  <date> <chr> <dbl> <chr>
                                   <dbl>
1 2018-09-17 LOM
                       0 PM10
2 2021-06-27 UIZ
                      4 PM10
3 1997-04-20 PED
                      5 PM10
4 2014-10-20 PED
                      5 PM10
5 2021-06-27 PED
                      5 PM10
6 2016-10-09 LPR 6 PM10
7 2017-09-10 LPR 6 PM10
8 2021-06-27 MER
              6 PM10
9 2021-06-27 NEZ
              6 PM10
10 2024-09-27 PED
                      6 PM10
# i 19,917 more rows
# i Use `print(n = ...)` to see more rows
```