



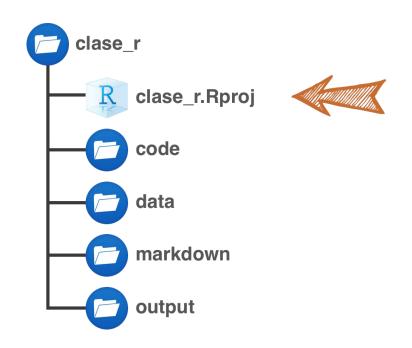
# Tidyverse

### José Luis Texcalac Sangrador

Procesamiento y visualización de datos espaciales en R



### Trabajar siempre con el proyecto de la clase



#### Clic a este archivo para abrir Rstudio y

- Generar script de clase
- Generar R Quarto para su laboratorio
- Generar R Markdown

#### Si la malla de datos está dentro de la carpeta data

R Quarto (.qmd) del laboratorio dentro de la carpeta markdown.
 read\_csv("../data/malla.csv")

Script de R (.r) de clase dentro de la carpeta code.
 read csv("./data/malla.csv")



### Encabezado de script vs YAML

Encabezado de script de R (.r)

```
title: "Introducción a Tidyverse"
subtitle: "Primer vistazo a tidyverse"
author: "Tex"
title-block-banner: true
date: today
format:
   html:
    theme: cosmo
editor: source
---
```

YAML R Quarto (.qmd)



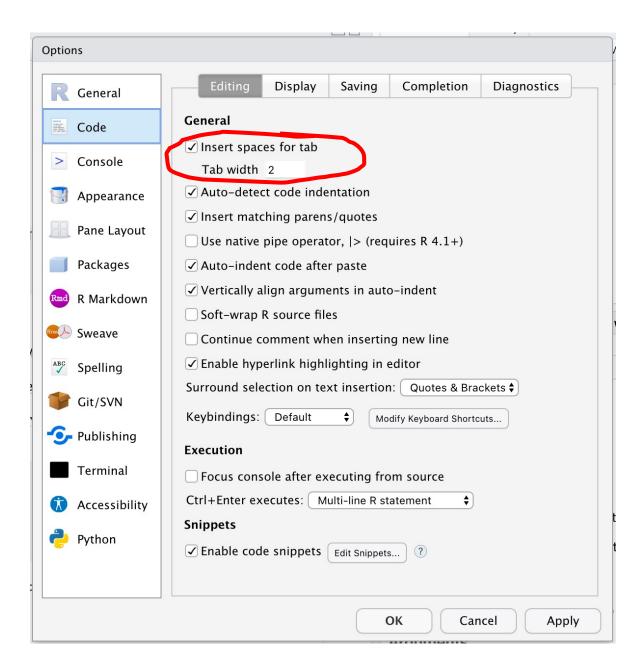
### Sugerencias para su scripts

#### Respetar patrón en nombre de archivos

- S06\_Tex
- L06\_Tex

```
# Procesamiento y visualización de datos espaciales en R
 # Sesión - 06
                                                  Nombre completo
 # Autor: José Luis Texcalac Sanrador 	—
 # Fecha: 07 de octubre 2021
 library(tidyverse)
                           Cargar todas las librerías a
 library(janitor)
                           utilizar al inicio de su script
 library(foreign)
 library(haven)
 ### Inicio procesamiento de datos
 malla <-
  read_csv("./tabla.csv") %>%
  clean_names() %>%
  print()
Use tabulaciones
```

























**Ø** Explorar

Principal

 $\bar{\blacksquare}$ 

Suscripcion..



(1) Historial



#### 46,443 vistas · hace 1 año Hack Club

Mira el AMA completo con Elon: https://www.youtube.com/watch? v=riru90zScwk Vea más clips de AMA de Elon: https://www.youtube ...

Subtítulos 🕩 Inglés

# Beginner Python

#### Beginner Python Tutorial 44 - Tabs vs Spaces

7,062 vistas · hace 1 año



Caleb Curry

https://calcur.tech/newsletter Instagram ...



44 - Tabs vs Spaces

#### Tabs vs Spaces on Silicon Valley

2,267 vistas • hace 5 años



Corey Donohoe

Kanye inspired tabs vs spaces scene in silicon valley on hbo.



#### Douglas Crockford Tabs vs Spaces

1,174 vistas • hace 1 año



downthecrop

De: The Post JavaScript Apocalypse - Douglas Crockford 2017 https://www.youtube.com/watch?v=NPB34IDZj3E Crockford ofrece ...

Subtítulos (3) Inglés





### Renombrar columnas: rename()

#### Sin guardar el resultado

```
pm10 %>%
  rename(est_dif = dif,
      est_cr = cruz_roja)
```

Primero el nuevo nombre

```
# tibble: 8,764 × 5
             hora est_dif est_cr nativitas
   fecha
   <date> <fct>
                    <dbl> <dbl>
                                       <db1>
 1 2014-01-01 0
                         NA
                                          NA
                               NA
 2 2014-01-01 1
                              57
                                         224
 3 2014-01-01 2
                              52
                                         118
                               45
 4 2014-01-01 3
                                          59
 5 2014-01-01 4
                               51
                                          40
 6 2014-01-01 5
                                          43
                                          39
 7 2014-01-01 6
                                42
                                          43
 8 2014-01-01 7
 9 2014-01-01 8
                                          46
10 2014-01-01 9
                                50
                                          47
# ... with 8,754 more rows
# i Use `print(n = ...)` to see more rows
```

Después el viejo nombre



# Identificar duplicados {janitor}: get\_dupes()

#### malla

	Site	2013	2014	2015
	CAM	51.0	42.8	39.9
	FAC	48.3	39.0	36.6
×	CAM	51.0	42.8	39.9
	IZT	44.6	39.3	35.0
X	FAC	48.3	39.0	36.6

#### malla %>% get\_dupes()

Site	2013	2014	2015	dupe_count
CAM	51.0	42.8	39.9	2
FAC	48.3	39.0	36.6	2



# Eliminar duplicados {dplyr}: distinct()

#### malla

	Site	2013	2014	2015
	CAM	51.0	42.8	39.9
	FAC	48.3	39.0	36.6
7	CAM	51.0	42.8	39.9
	IZT	44.6	39.3	35.0
X	FAC	48.3	39.0	36.6

#### Elimina filas duplicadas

malla %>% distinct()

Site	2013	2014	2015
CAM	51.0	42.8	39.9
FAC	48.3	39.0	36.6
IZT	44.6	39.3	35.0



### Identificar duplicados {janitor}: get\_dupes()

#### nombres

	nombre	edad	peso	pelo
	Luis	49	81.3	Rizado
	Juan	58	79.4	Lacio
	Pedro	51	80.7	Lacio
X	Luis	49	81.3	
×	Pedro	51	80.7	

#### nombres %>% get\_dupes(nombre, edad, peso)

nombre	edad	peso	dupe_count	pelo
Luis	49	81.3	2	Rizado
Luis	49	81.3	2	""
Pedro	51	80.7	2	Lacio
Pedro	51	80.7	2	""



#### Eliminar duplicados en columnas seleccionadas

(	nombre	edad	peso	) pelo
	Luis	49	81.3	Rizado
	Juan	58	79.4	Lacio
	Pedro	51	80.7	Lacio
	Luis	49	81.3	
	Pedro	51	80.7	



nombre	edad	peso	pelo
Luis	49	81.3	Rizado
Juan	58	79.4	Lacio
Pedro	51	80.7	Lacio

- El resultado es una tabla sin duplicados en columnas seleccionadas
- El argumento .keep\_all = TRUE permite mantener todas las columnas



### Contar repeticiones de valores: count()

malla					
Site	2013	2014	2015		
CAM	51.0	42.8	39.9		
FAC	48.3	39.0	36.6		
CAM	51.0	42.8	39.9		
IZT	44.6	39.3	35.0		
FAC	48.3	39.0	36.6		

- Alternativa para identificar y contabilizar los duplicados
- Útil con pocas variables

```
malla %>%
count(site, 2013, 2014, 2015, name = "tot_rep")
```

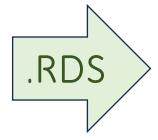


# Exportar malla de datos



write\_excel\_csv(malla, "ruta y nombre de archivo.csv")

write\_excel\_csv(malla, "./data/malla.csv")



write\_rds(malla, "ruta y nombre de archivo.rds")

write\_rds(malla, "./data/malla.rds")



### Su turno...

- Abra su proyecto y genere su script de clase
- Exporte el objeto ozono
- Guarde el archivo como ozono\_wide.rds
- Reinicie su sesión de R
  - Session\Restart R
- Continúe en su script
- Importe el archivo ozono\_wide.rds y nombre al objeto como ozono\_w





#### Estructura de la malla de datos

edo	mun	nom_mun	pob_tot	pob_fem	pob_mas
02	001	Ensenada	443,807	222,500	221,307
02	002	Mexicali	1,049,792	520,544	529,248
02	004	Tijuana	1,922,523	953,783	968,740

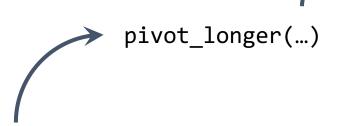
wide

#### long

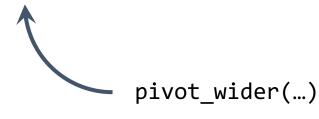
edo	mun	nom_mun	nom_vars	pob
02	001	Ensenada	pob_tot	443,807
02	002	Ensenada	pob_fem	222,500
02	004	Ensenada	pob_mas	221,307
02	001	Mexicali	pob_tot	1,049,792
02	002	Mexicali	pob_fem	520,544
02	004	Mexicali	pob_mas	529,248
02	001	Tijuana	pob_tot	1,922,523
02	002	Tijuana	pob_fem	953,783
02	004	Tijuana	pob_mas	968,740



### Transformar malla de datos a wide y long



edo	mun	nom_mun	pob_tot	pob_fem	pob_mas
02	001	Ensenada	443,807	222,500	221,307
02	002	Mexicali	1,049,792	520,544	529,248
02	004	Tijuana	1,922,523	953,783	968,740



edo	mun	nom_mun	nom_vars	pob
02	001	Ensenada	pob_tot	443,807
02	002	Ensenada	pob_fem	222,500
02	004	Ensenada	pob_mas	221,307
02	001	Mexicali	pob_tot	1,049,792
02	002	Mexicali	pob_fem	520,544
02	004	Mexicali	pob_mas	529,248
02	001	Tijuana	pob_tot	1,922,523
02	002	Tijuana	pob_fem	953,783
02	004	Tijuana	pob_mas	968,740



# pivot\_longer()

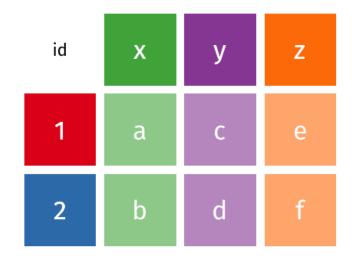
```
malla %>%

pivot_longer(cols = ...,

names_to = ...,

values_to = ...,

names_prefix = ...)
```





# pivot\_longer(...)

edo	mun	иот_тип	pob_tot	Pob_fem	pob_mas
02	001	Ensenada	443,807	222,500	221,307
02	002	Mexicali	1,049,792	520,544	529,248
02	004	Tijuana	1,922,523	953,783	968,740

Transformar de wide a long

edo	mun	пот_тип	nom_vars	Pop
02	001	Ensenada	pob_tot	443,807
02	002	Ensenada	pob_fem	222,500
02	004	Ensenada	pob_mas	221,307
02	001	Mexicali	pob_tot	1,049,792
02	002	Mexicali	pob_fem	520,544
02	004	Mexicali	pob_mas	529,248
02	001	Tijuana	pob_tot	1,922,523
02	002	Tijuana	pob_fem	953,783
02	004	Tijuana	pob_mas	968,740



- ✓ cols = c(pob\_tot, pob\_mas)
- ✓ cols = pob\_tot:pob\_mas



edo pob\_tot pob\_fem pob\_mas mun nom\_mun 001 02 Ensenada 443807 222500 221307 002 Mexicali 02 1049792 520544 529248 02 004 Tijuana 1922523 953783 968740

values\_to = "pob")

Si no se especifica no se borra el prefijo

edo	mun	nom_mun	nom_vars	pob
02	001	Ensenada	tot	443,807
02	002	Ensenada	fem	222,500
02	004	Ensenada	mas	221,307
02	001	Mexicali	tot	1,049,792
02	002	Mexicali	fem	520,544
02	004	Mexicali	mas	529,248
02	001	Tijuana	tot	1,922,523
02	002	Tijuana	fem	953,783
02	004	Tijuana	mas	968,740



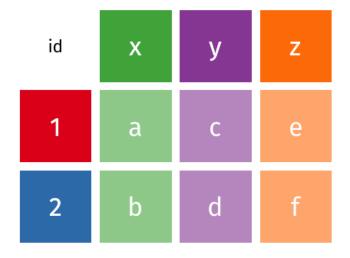
# pivot\_wider()

```
malla %>%

pivot_wider(names_from = ...,

names_prefix = ...,

values_to = ...)
```





edo	mun	nom_mun	nom_vars	pob
02	001	Ensenada	pob_tot	443,807
02	002	Ensenada	pob_fem	222,500
02	004	Ensenada	pob_mas	221,307
02	001	Mexicali	pob_tot	1,049,792
02	002	Mexicali	pob_fem	520,544
02	004	Mexicali	pob_mas	529,248
02	001	Tijuana	pob_tot	1,922,523
02	002	Tijuana	pob_fem	953,783
02	004	Tijuana	pob_mas	968,740

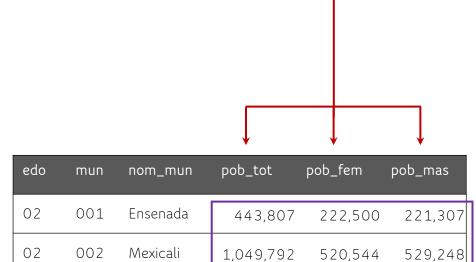
Transformar \
de long a
wide

edo	mun	nom_mun	pob_tot	pob_fem	pob_mas
02	001	Ensenada	443,807	222,500	221,307
02	002	Mexicali	1,049,792	520,544	529,248
02	004	Tijiwawa	1,922,523	953,783	968,740



#### 

edo	mun	nom_mun	nom_vars	pob
02	001	Ensenada	tot	443,807
02	002	Ensenada	fem	222,500
02	004	Ensenada	mas	221,307
02	001	Mexicali	tot	1,049,792
02	002	Mexicali	fem	520,544
02	004	Mexicali	mas	529,248
02	001	Tijuana	tot	1,922,523
02	002	Tijuana	fem	953,783
02	004	Tijuana	mas	968,740



1,922,523

953,783

968,740

004

Tijuana

02



### Su turno...

- Trabaje con la malla ozono\_w
  - Transforme la malla de wide a long
  - Guarde el resultado como ozono\_l





### Agrupar datos: group\_by()

```
malla %>% group_by(...) %>% summarise(...)

Malla de datos a agrupar
Argumentos de agrupación

Argumentos de resumen
```

```
malla %>%
  group_by(var1)
  summarise(tot_var2 = sum(var2, na.rm = TRUE))
```



# Agrupar datos... group\_by()

malla

%>% group\_by(entidad)

%>%

summarise(...)

entidad	municipio	población	
Aguascalientes	Asientos	51,536	_
Aguascalientes	Calvillo	58,250	
Baja California	Ensenada	443,807	
Baja California	Mexicali	1.049.792	
Ciudad de México	Azcapotzalco	432,205	
Ciudad de México	Benito Juárez	434,153	

Aguascalientes	Asientos	51,536
Aguascalientes	Calvillo	58,250

Baja California	Ensenada	443,807
Baja California	Mexicali	1,049,792

Ciudad de México	Azcapotzalco	432,205
Ciudad de M <b>é</b> xico	Benito Juárez	434,153

entidad	mean	sum	n
Aguascalientes	54,893.0	109,786	2
Baja California	433,179.0	1,493,599	2
Ciudad de México	740,998.5	866,358	2

```
malla %>%
  group_by(entidad) %>%
  summarise(mean = mean(población),
            sum = sum(población),
            n = n()
```



### Su turno...

- Trabaje con la malla ozono\_l
- Agrupe por fecha y calcule el promedio y desviación estándar.
- Guarde el resultado como o3\_dia





#### **Tidy Animated Verbs**

Garrick Aden-Buie – @grrrck – garrickadenbuie.com. Set operations contributed by Tyler Grant Smith.

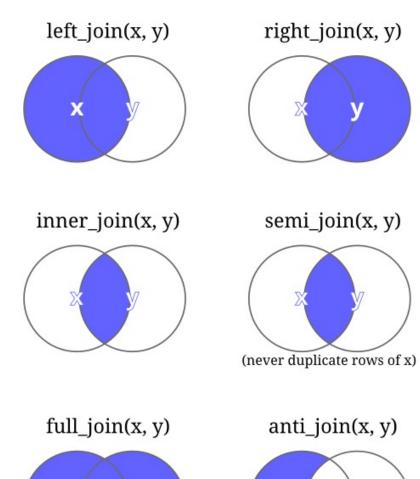
```
launch binder license (images) CC0 license (code) MIT
```

- Mutating Joins inner\_join(), left\_join(), right\_join(), full\_join()
- Filtering Joins semi\_join(), anti\_join()
- Set Operations union(), union\_all(), intersect(), setdiff()
- Tidy Data spread() and gather()
- Learn more about
  - Using the animations and images
  - Relational Data
  - o gganimate



# Unión de mallas de datos

#### dplyr joins





# inner\_join(tbl\_1, tbl\_2, by = "cvegeo")

tbl\_1 tbl\_2

cvegeo	nom_mun
17007	Cuernavaca
17020	Tepoztlán
17028	Xochitepec

cvegeo	cve_sun
17009	M17.02
17011	M17.02
17020	M17.02

cvegeo	nom_mun	cve_sun
17020	Tepoztlán	M17.02



### inner\_join(tbl\_1, tbl\_2, by = "cvegeo")

tbl\_1

cvegeo	nom_mun	
17017	Puente de Ixtla	
17020	Tepoztlán	
17028	Xochitepec	

tbl\_2

cvegeo	cve_sun
17009	M17.02
17011	M17.02
17017	P17.01
17017	C17.02

cvegeo	nom_mun	cve_sun
17017	Puente de Ixtla	P17.01
17017	Puente de Ixtla	C17.02

# Argumento by

Si el nombre del identificador de ambas columnas no coincide entonces:

En la unión se mantiene el nombre de la columna de la tabla X



#### inner\_join(tbl\_1, tbl\_2, by = c("cvegeo" = "cve\_mun"))

tbl\_1

cvegeo	nom_mun	
17017	Puente de Ixtla	
17020	Tepoztlán	
17028	Xochitepec	

tbl\_2

cve_mun	cve_sun
17009	M17.02
17011	M17.02
17017	P17.01
17017	C17.02

cvegeo	nom_mun	cve_sun
17017	Puente de Ixtla	P17.01
17017	Puente de Ixtla	C17.02



# left\_join(tbl\_1, tbl\_2, by = "cvegeo")

tbl\_1

cvegeo	nom_mun
17007	Cuernavaca
17020	Tepoztlán
17028	Xochitepec

tbl\_2

cvegeo	cve_sun
17009	M17.02
17011	M17.02
17020	M17.02

cvegeo	nom_mun	cve_sun
17007	Cuernavaca	NA
17020	Tepoztlán	M17.02
17028	Xochitepec	NA



# right\_join(tbl\_1, tbl\_2, by = "cvegeo")

tbl\_1

cvegeo	nom_mun
17007	Cuernavaca
17020	Tepoztlán
17028	Xochitepec

tbl\_2

cvegeo	cve_sun
17009	M17.02
17011	M17.02
17020	M17.02

cvegeo	nom_mun	cve_sun
17009	NA	M17.02
17011	NA	M17.02
17020	Tepoztlán	M17.02



# full\_join(tbl\_1, tbl\_2, by = "cvegeo")

tbl\_1

cvegeo	cve_mun
17007	Cuernavaca
17020	Tepoztlán
17028	Xochitepec

tbl\_2

cvegeo	cve_sun
17009	M17.02
17011	M17.02
17020	M17.02

cvegeo	nom_mun	cve_sun
17007	Cuernavaca	NA
17009	NA	M17.02
17011	NA	M17.02
17020	Tepoztlán	M17.02
17028	Xochitepec	NA