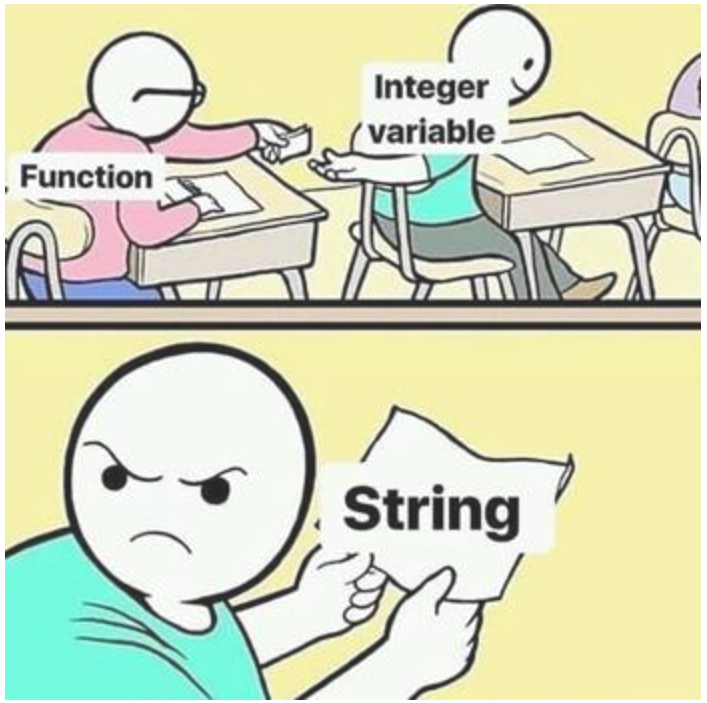

INSP/ESPM
Escuela de Salud Pública de México

Factores, texto y fechas

{forcats, stringr, lubridate}

José Luis Texcalac Sangrador

Procesamiento y visualización de datos espaciales en R

Factores en R

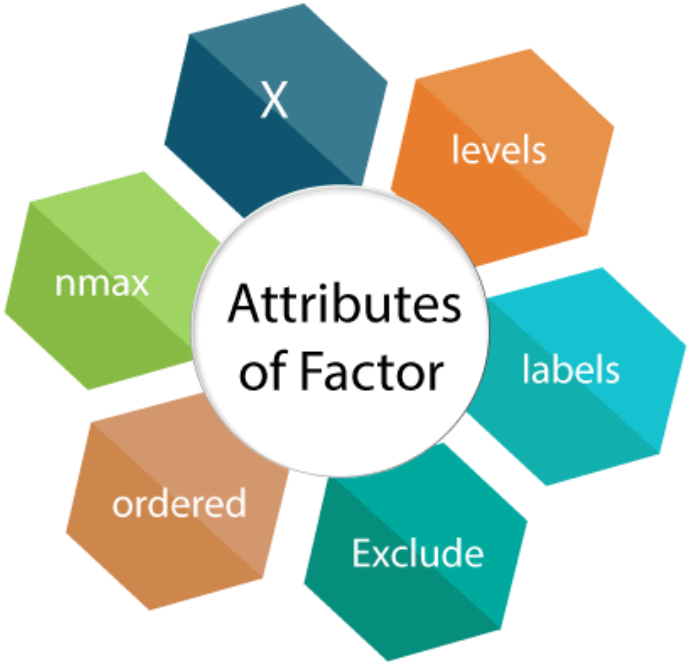

- Se usan para trabajar con variables categóricas, es decir, variables que tienen un conjunto fijo y conocido de valores posibles.
- Son útiles cuando quieres mostrar vectores de caracteres en un orden no alfabético.
- Los valores que un factor puede contener están delimitados por los niveles, es decir, las diferentes categorías presentes en una variable.
- Los niveles pueden estar codificados tanto en valores numéricos como caracteres.

Factores

```
star_wars <-
  starwars %>%
  select(name, height, mass, sex, species) %>%
  print()
```

```
# A tibble: 87 × 5
   name               height  mass sex    species
   <chr>               <int> <dbl> <chr>  <chr>
 1 Luke Skywalker        172    77 male   Human
 2 C-3PO                 167    75 none   Droid
 3 R2-D2                  96    32 none   Droid
 4 Darth Vader           202   136 male   Human
 5 Leia Organa           150    49 female Human
 6 Owen Lars             178   120 male   Human
 7 Beru Whitesun Lars    165    75 female Human
 8 R5-D4                  97    32 none   Droid
 9 Biggs Darklighter     183    84 male   Human
10 Obi-Wan Kenobi        182    77 male   Human
# ℹ 77 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Factores

```
summary(star_wars)
```

```
    name                height           mass
Length:87           Min.   : 66.0   Min.   :  15.00
Class :character    1st Qu.:167.0   1st Qu.:  55.60
Mode  :character    Median :180.0   Median :  79.00
                    Mean   :174.6   Mean   :  97.31
                    3rd Qu.:191.0   3rd Qu.:  84.50
                    Max.   :264.0   Max.   :1358.00
                    NA's   :6       NA's   :28
    sex              species
Length:87           Length:87
Class :character    Class :character
Mode  :character    Mode  :character
```

Vector o variable a categorizar

Etiquetas que toma la variable

```
factor(variable, levels, labels)
```

Niveles que toma la variable

Valores distintos en un vector o variable

```
unique(star_wars$sex)
```

```
> unique(star_wars$sex)
[1] "male"           "none"           "female"
[4] "hermaphroditic" NA
```

```
unique(star_wars$species)
```

```
 [1] "Human"          "Droid"          "Wookiee"
 [4] "Rodian"         "Hutt"           NA
 [7] "Yoda's species" "Trandoshan"     "Mon Calamari"
[10] "Ewok"           "Sullustan"      "Neimodian"
[13] "Gungan"         "Toydarian"      "Dug"
[16] "Zabrak"         "Twi'lek"        "Aleena"
[19] "Vulptereen"     "Xexto"          "Toong"
[22] "Cerean"         "Nautolan"       "Tholothian"
[25] "Iktotchi"       "Quermian"       "Kel Dor"
[28] "Chagrian"       "Geonosian"      "Mirialan"
[31] "Clawdite"       "Besalisk"       "Kaminoan"
[34] "Skakoan"        "Muun"           "Togruta"
[37] "Kaleesh"        "Pau'an"
```

factores

```
star_wars <-
  star_wars %>%
  mutate(sexo = factor(sex,
                       levels = c("male", "female",
                                  "hermaphroditic", "none")),
         especie = factor(species)) %>%
  print()
```

```
    name              height           mass            sex
Length:87          Min.   : 66.0   Min.   :  15.00   Length:87
Class :character   1st Qu.:167.0   1st Qu.:  55.60   Class :character
Mode  :character   Median :180.0   Median :  79.00   Mode  :character
                   Mean   :174.6   Mean   :  97.31
                   3rd Qu.:191.0   3rd Qu.:  84.50
                   Max.   :264.0   Max.   :1358.00
                   NA's   :6       NA's   :28
  species                    sexo         especie
Length:87          male          :60   Human   :35
Class :character   female        :16   Droid   : 6
Mode  :character   hermaphroditic: 1   Gungan  : 3
                   none          : 6   Kaminoan: 2
                   NA's          : 4   Mirialan: 2
                                       (Other) :35
                                       NA's    : 4
```

Factores

Vector o variable a categorizar

Niveles que toma la variable

Etiquetas que toma la variable

```
factor(variable,  levels,  labels)
```

```
malla
```

nombre	ojos	pelo	ojos_f	pelo_f
Luisa	azules	1	azules	lacio
Juana	negros	2	negros	rizado
Petra	azules	2	azules	rizado
María	verdes	NA	verdes	NA
Andrea	negros	1	negros	lacio

```
malla <-
  malla %>%
  mutate(ojos_f = factor(ojos,
                         levels = c("azules", "negros",
                                    "verdes", "grises")),
  pelo_f = factor(pelo,
                  levels = c(1, 2),
                  labels = c("lacio", "rizado"))) %>%
  print()
```

```
summary(malla)
```

```
   nombre              ojos                pelo       ojos_f     pelo_f
Length:5           Length:5           Min.   :1.0   azules:2   lacio :2
Class :character   Class :character   1st Qu.:1.0   negros:2   rizado:2
Mode  :character   Mode  :character   Median :1.5   verdes:1   NA's  :1
                                      Mean   :1.5   grises:0
                                      3rd Qu.:2.0
                                      Max.   :2.0
                                      NA's   :1
```

Trabajando con factores en R {forcats}

- Reordenar niveles en malla de datos y/o gráficos
- Rectificar niveles
- Agregar niveles

Su turno...

- Importe la malla promedios_2021_ps.csv
- Nombre a su objeto como contam
- Columnas en formato **snake case**

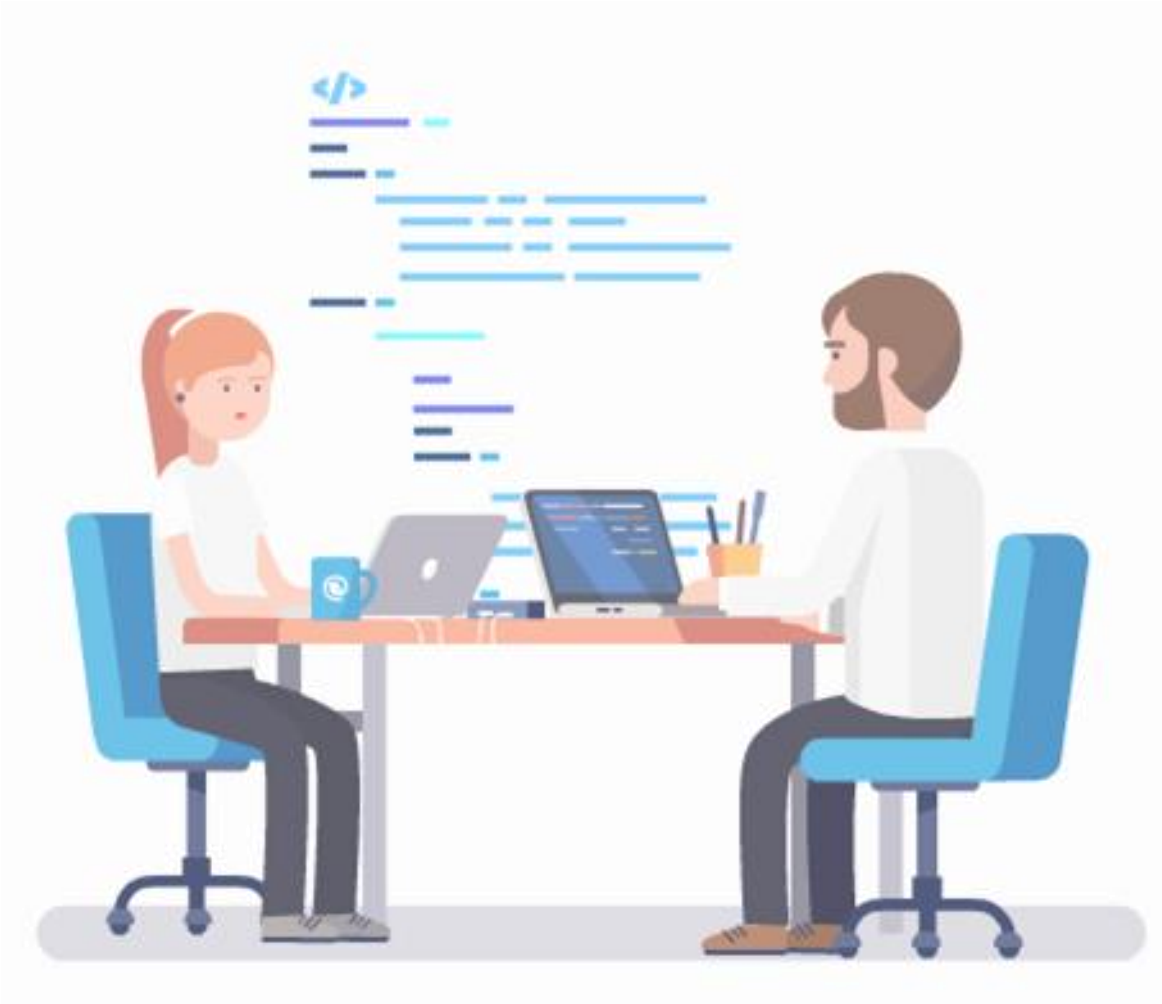


```
contam <-
  read_csv("./data/promedios_2021_ps.csv", skip = 8) %>%
  clean_names() %>%
  print()
```

```
Rows: 6692 Columns: 5
```

```
── Column specification ────────────────────────────────────────────────────────
```

```
Delimiter: ","
chr (3): date, id_station, id_parameter
dbl (2): value, unit

ℹ Use `spec()` to retrieve the full column specification for this data.
ℹ Specify the column types or set `show_col_types = FALSE` to quiet this message.
# A tibble: 6,692 × 5
   date       id_station id_parameter value  unit
   <chr>      <chr>      <chr>        <dbl> <dbl>
 1 01/01/2021 ACO        PM10            70     2
 2 01/01/2021 ATI        PM10            44     2
 3 01/01/2021 CUT        PM10            73     2
 4 01/01/2021 FAC        PM10            43     2
 5 01/01/2021 MER        PM10            56     2
 6 01/01/2021 MER        PM2.5           40     2
 7 01/01/2021 NEZ        PM2.5           29     2
 8 01/01/2021 PED        PM10            34     2
 9 01/01/2021 PED        PM2.5           25     2
10 01/01/2021 SAG        PM10            59     2
# … with 6,682 more rows
```

Su turno...

```
summary(contam)
```

```
    date           id_station        id_parameter          value              unit
Length:6692        Length:6692        Length:6692        Min.   :  2.00   Min.   :2
Class :character   Class :character   Class :character   1st Qu.: 17.00   1st Qu.:2
Mode  :character   Mode  :character   Mode  :character   Median : 25.00   Median :2
                                                         Mean   : 30.46   Mean   :2
                                                         3rd Qu.: 39.00   3rd Qu.:2
                                                         Max.   :158.00   Max.   :2
```

- Identifique en la malla contam las variables que requieran codificarse como factor
- Convierta a factor las variables identificadas.
- Nombre a las nuevas columnas como site y pollutant.
- Ejecute el comando summary.
- Elimine las columnas id_station, id_parameter y unit.
- Renombre a la columna value como concentration.


```
contam <-
  contam %>%
  mutate(site = factor(id_station),
         pollutant = factor(id_parameter)) %>%
  print()
```

```
summary(contam)
```

```
     date           id_station        id_parameter          value              unit          site       pollutant
Length:6692        Length:6692        Length:6692        Min.   :  2.00   Min.   :2   BJU     : 482   PM10 :3529
Class :character   Class :character   Class :character   1st Qu.: 17.00   1st Qu.:2   MER     : 478   PM2.5:3163
Mode  :character   Mode  :character   Mode  :character   Median : 25.00   Median :2   PED     : 470
                                                         Mean   : 30.46   Mean   :2   TLA     : 432
                                                         3rd Qu.: 39.00   3rd Qu.:2   SFE     : 386
                                                         Max.   :158.00   Max.   :2   CAM     : 364
                                                                                      (Other):4080
```

```
contam <-
  contam %>%
  select(-c(id_station, id_parameter, unit)) %>%
  rename(concentration = value)
  print()
```

```
summary(contam)
```

```
     date           concentration         site       pollutant
Length:6692        Min.   :  2.00   BJU     : 482   PM10 :3529
Class :character   1st Qu.: 17.00   MER     : 478   PM2.5:3163
Mode  :character   Median : 25.00   PED     : 470
                   Mean   : 30.46   TLA     : 432
                   3rd Qu.: 39.00   SFE     : 386
                   Max.   :158.00   CAM     : 364
                                    (Other):4080
```

Fechas con código base

Columna o vector con fechas
en algún formato consistente

- mes-día-año
- año/mes/dia

Formato de la fecha

```
as.Date(fecha,  format)
```

```
malla
```

fecha	valor
12/11/19	12.1
31/01/21	13.4
28/02/17	11.8
03/09/18	14.4
22/11/20	12.7

%d/%m/%y

```
malla %>%
  mutate(fecha = as.Date(fecha, format = "%d/%m/%y"))
```

fecha	valor
2019-11-12	12.1
2021-01-31	13.4
2017-02-28	11.8
2018-09-03	14.4
2020-11-22	12.7

Fechas con código base

```
malla
```

fecha	valor
12-11-2019	12.1
31-01-2021	13.4
28-02-2017	11.8
03-09-2018	14.4
22-11-2020	12.7

%d-%m-%Y

```
malla %>%
  mutate(fecha = as.Date(fecha, format = "%d-%m-%Y"))
```

fecha	valor
2019-11-12	12.1
2021-01-31	13.4
2017-02-28	11.8
2018-09-03	14.4
2020-11-22	12.7

Code	Value
%d	Day of the month (decimal number)
%m	Month (decimal number)
%b	Month (abbreviated)
%B	Month (full name)
%y	Year (2 digit)
%Y	Year (4 digit)

https://www.stat.berkeley.edu/~s133/dates.html

INSP/ESPM
Escuela de Salud Pública de México

Fechas usando el paquete {lubridate}

```
malla
```

fecha	valor
12-11-2019	12.1
31-01-2021	13.4
28-02-2017	11.8
03-09-2018	14.4
22-11-2020	12.7

```
malla %>%
  mutate(fecha = dmy(fecha))
```

fecha	valor
2019-11-12	12.1
2021-01-31	13.4
2017-02-28	11.8
2018-09-03	14.4
2020-11-22	12.7

fecha	valor
12-2019-11	12.1
31-2021-01	13.4
28-2017-02	11.8
03-2018-09	14.4
22-2020-11	12.7

```
malla %>%
  mutate(fecha = dym(fecha))
```

```r
today()                          # devuelve la fecha actual

year("2020-11-05")               # devuelve el año de la fecha indicada

month("2020-11-05")              # devuelve el mes de la fecha indicada

day("2020-11-05")                # devuelve el día de la fecha indicada

wday("2020-11-05")               # devuelve el número de la semana de la fecha indicada

yday("2020-11-05")               # devuelve el número de día del año de la fecha indicada
```

```r
malla %>%
  mutate(mes = month(fecha, label = TRUE))
```

fecha	valor	mes
2019-11-12	12.1	nov
2021-01-31	13.4	ene
2017-02-28	11.8	feb

Dates and times with lubridate : : CHEAT SHEET

https://lubridate.tidyverse.org

Date-times

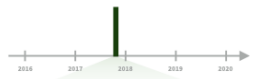

`2017-11-28 12:00:00`

`2017-11-28 12:00:00`
A **date-time** is a point on the timeline, stored as the number of seconds since 1970-01-01 00:00:00 UTC

dt <- ***as_datetime****(1511870400)*
"2017-11-28 12:00:00 UTC"

`2017-11-28`
A **date** is a day stored as the number of days since 1970-01-01

d <- ***as_date****(17498)*
"2017-11-28"

`12:00:00`
An hms is a **time** stored as the number of seconds since 00:00:00

*t <- hms::****as.hms****(85)*
00:01:25

PARSE DATE-TIMES (Convert strings or numbers to date-times)

1. Identify the order of the year (**y**), month (**m**), day (**d**), hour (**h**), minute (**m**) and second (**s**) elements in your data.
2. Use the function below whose name replicates the order. Each accepts a wide variety of input formats.

`2017-11-28T14:02:00` **ymd_hms**(), **ymd_hm**(), **ymd_h**(). *ymd_hms("2017-11-28T14:02:00")*

`2017-22-12 10:00:00` **ydm_hms**(), **ydm_hm**(), **ydm_h**(). *ydm_hms("2017-22-12 10:00:00")*

`11/28/2017 1:02:03` **mdy_hms**(), **mdy_hm**(), **mdy_h**(). *mdy_hms("11/28/2017 1:02:03")*

`1 Jan 2017 23:59:59` **dmy_hms**(), **dmy_hm**(), **dmy_h**(). *dmy_hms("1 Jan 2017 23:59:59")*

`20170131` **ymd**(), **ydm**(). *ymd(20170131)*

`July 4th, 2000` **mdy**(), **myd**(). *mdy("July 4th, 2000")*

`4th of July '99` **dmy**(), **dym**(). *dmy("4th of July '99")*

`2001: Q3` **yq**() Q for quarter. *yq("2001: Q3")*

`2:01` hms::**hms**() Also lubridate::**hms**(), **hm**() and **ms**(), which return periods.* *hms::hms(sec = 0, min= 1, hours = 2)*

`2017.5` **date_decimal**(decimal, tz = "UTC") *date_decimal(2017.5)*

now(tzone = "") Current time in tz (defaults to system tz). *now()*

today(tzone = "") Current date in a tz (defaults to system tz). *today()*

fast_strptime() Faster strptime. *fast_strptime('9/1/01', '%y/%m/%d')*

parse_date_time() Easier strptime. *parse_date_time("9/1/01", "ymd")*

GET AND SET COMPONENTS

Use an accessor function to get a component.
d ## "2017-11-28"
day(d) ## 28

Assign into an accessor function to change a component in place.
day(d) <- 1
d ## "2017-11-01"

`2018-01-31 11:59:59` **date**(x) Date component. *date(dt)*

`2018-01-31 11:59:59` **year**(x) Year. *year(dt)*
isoyear(x) The ISO 8601 year.
epiyear(x) Epidemiological year.

`2018-01-31 11:59:59` **month**(x, label, abbr) Month. *month(dt)*

`2018-01-31 11:59:59` **day**(x) Day of month. *day(dt)*
wday(x,label,abbr) Day of week.
qday(x) Day of quarter.

`2018-01-31 11:59:59` **hour**(x) Hour. *hour(dt)*

`2018-01-31 11:59:59` **minute**(x) Minutes. *minute(dt)*

`2018-01-31 11:59:59` **second**(x) Seconds. *second(dt)*

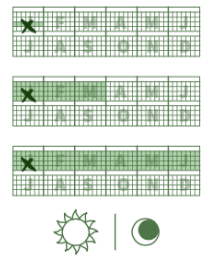

week(x) Week of the year. *week(dt)*
isoweek() ISO 8601 week.
epiweek() Epidemiological week.

quarter(x, with_year = FALSE) Quarter. *quarter(dt)*

semester(x, with_year = FALSE) Semester. *semester(dt)*

am(x) Is it in the am? *am(dt)*
pm(x) Is it in the pm? *pm(dt)*

dst(x) Is it daylight savings? *dst(d)*

leap_year(x) Is it a leap year? *leap_year(d)*

update(object, ..., simple = FALSE) *update(dt, mday = 2, hour = 1)*

Round Date-times

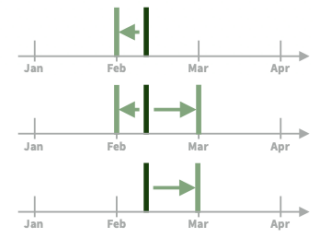

floor_date(x, unit = "second") Round down to nearest unit. *floor_date(dt, unit = "month")*

round_date(x, unit = "second") Round to nearest unit. *round_date(dt, unit = "month")*

ceiling_date(x, unit = "second", change_on_boundary = NULL) Round up to nearest unit. *ceiling_date(dt, unit = "month")*

rollback(dates, roll_to_first = FALSE, preserve_hms = TRUE) Roll back to last day of previous month. *rollback(dt)*

Stamp Date-times

stamp() Derive a template from an example string and return a new function that will apply the template to date-times. Also **stamp_date**() and **stamp_time**().

1. Derive a template, create a function
   sf <- stamp("Created Sunday, Jan 17, 1999 3:34")
2. Apply the template to dates
   sf(ymd("2010-04-05"))
   ## [1] "Created Monday, Apr 05, 2010 00:00"

Tip: use a date with day > 12

Time Zones

R recognizes ~600 time zones. Each encodes the time zone, Daylight Savings Time, and historical calendar variations for an area. R assigns *one* time zone per vector.

Use the **UTC** time zone to avoid Daylight Savings.

OlsonNames() Returns a list of valid time zone names. *OlsonNames()*

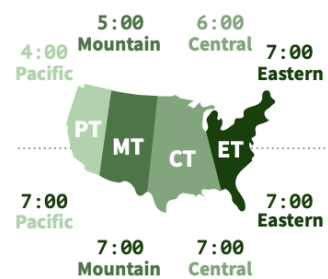

with_tz(time, tzone = "") Get the **same date-time** in a new time zone (a new clock time). *with_tz(dt, "US/Pacific")*

force_tz(time, tzone = "") Get the **same clock time** in a new time zone (a new date-time). *force_tz(dt, "US/Pacific")*

Su turno...

- Convierta a formato de fecha la columna date
- Genere columnas day, month (con etiqueta), year
- Guarde el objeto con el mismo nombre
- Genere el **summary** de la malla de datos


```r
contam <-
  contam %>%
  mutate(date = as.Date(date, format = "%d/%m/%Y"),
         day = day(date),
         month = month(date, label = TRUE),
         year = year(date)) %>%
  print()
```

```
# A tibble: 6,692 × 7
   date       concentration site  pollutant   day month  year
   <date>             <dbl> <fct> <fct>     <int> <ord> <dbl>
 1 2021-01-01            70 ACO   PM10          1 ene    2021
 2 2021-01-01            44 ATI   PM10          1 ene    2021
 3 2021-01-01            73 CUT   PM10          1 ene    2021
 4 2021-01-01            43 FAC   PM10          1 ene    2021
 5 2021-01-01            56 MER   PM10          1 ene    2021
 6 2021-01-01            40 MER   PM2.5         1 ene    2021
 7 2021-01-01            29 NEZ   PM2.5         1 ene    2021
 8 2021-01-01            34 PED   PM10          1 ene    2021
 9 2021-01-01            25 PED   PM2.5         1 ene    2021
10 2021-01-01            59 SAG   PM10          1 ene    2021
# … with 6,682 more rows
```

```r
summary(contam)
```

```
     date             concentration        site          pollutant        day              month          year
Min.   :2021-01-01   Min.   :  2.00   BJU     : 482   PM10 :3529   Min.   : 1.00   jul     : 919   Min.   :202
1st Qu.:2021-03-06   1st Qu.: 17.00   MER     : 478   PM2.5:3163   1st Qu.: 8.00   may     : 917   1st Qu.:202
Median :2021-05-07   Median : 25.00   PED     : 470                Median :16.00   jun     : 851   Median :202
Mean   :2021-05-04   Mean   : 30.46   TLA     : 432                Mean   :15.69   mar     : 843   Mean   :202
3rd Qu.:2021-07-03   3rd Qu.: 39.00   SFE     : 386                3rd Qu.:23.00   ene     : 834   3rd Qu.:202
Max.   :2021-08-31   Max.   :158.00   CAM     : 364                Max.   :31.00   ago     : 831   Max.   :202
                                      (Other):4080                                 (Other):1497
```

Malla incial

```
    date            id_station        id_parameter          value              unit
Length:6692        Length:6692        Length:6692        Min.   :  2.00   Min.   :2
Class :character   Class :character   Class :character   1st Qu.: 17.00   1st Qu.:2
Mode  :character   Mode  :character   Mode  :character   Median : 25.00   Median :2
                                                         Mean   : 30.46   Mean   :2
                                                         3rd Qu.: 39.00   3rd Qu.:2
                                                         Max.   :158.00   Max.   :2
```

Malla procesada

```
      date            concentration          site          pollutant          day              month          year
Min.   :2021-01-01   Min.   :  2.00   BJU     : 482   PM10 :3529   Min.   : 1.00   jul     : 919   Min.   :2021
1st Qu.:2021-03-06   1st Qu.: 17.00   MER     : 478   PM2.5:3163   1st Qu.: 8.00   may     : 917   1st Qu.:2021
Median :2021-05-07   Median : 25.00   PED     : 470                Median :16.00   jun     : 851   Median :2021
Mean   :2021-05-04   Mean   : 30.46   TLA     : 432                Mean   :15.69   mar     : 843   Mean   :2021
3rd Qu.:2021-07-03   3rd Qu.: 39.00   SFE     : 386                3rd Qu.:23.00   ene     : 834   3rd Qu.:2021
Max.   :2021-08-31   Max.   :158.00   CAM     : 364                Max.   :31.00   ago     : 831   Max.   :2021
                                      (Other):4080                                 (Other):1497
```

Su turno...

- Filtre el contaminante $PM_{2.5}$
- Renombre la columna concentration como pm25
- Genere una nueva malla sólo con las columnas date, site y pm25, nombre al objeto como **pm25**
- Exporte su malla **pm25** con el nombre **pm25_cdmx_2021** con extensión rds y csv

INSP/ESPM
Escuela de Salud Pública de México

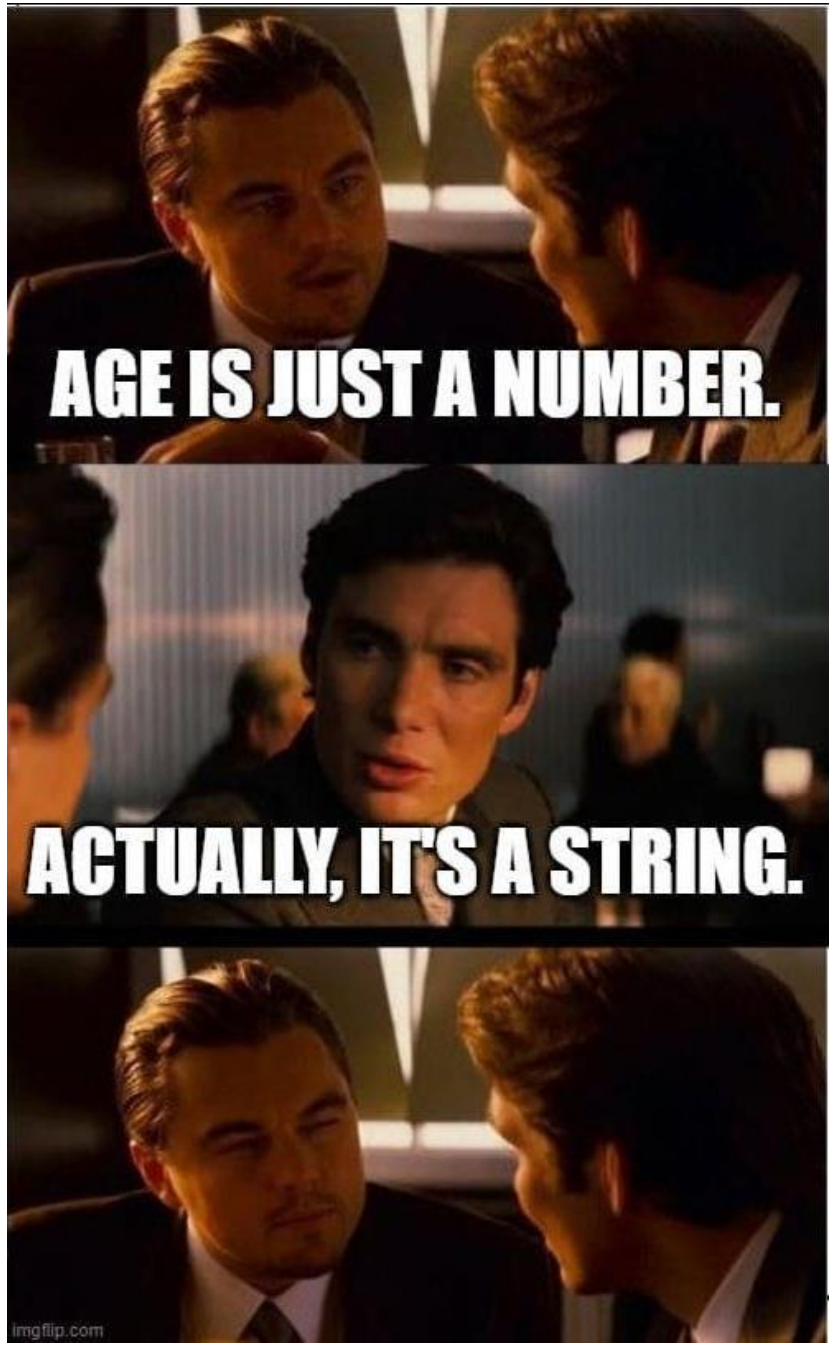

str_c(..., sep = "")

str_c

Permite concatenar (unir) el texto de dos o más columnas en una sola.

```
dataset %>%
  mutate(folio = str_c(posgrado, matricula, sexo)) %>%
  print()
```

matricula	sexo	Posgrado	folio
0718	1	MCSA	MCSA07181
2183	2	MCEP	MCEP21832
1241	1	MCSS	MCSS12411
0213	2	MCSA	MCSA02132
4386	2	MCBI	MCBI43862

str_c(..., sep = "")

```
dataset %>%
  mutate(folio = str_c(posgrado,
                       matricula,
                       sexo,
                        sep = "-")) %>%
  print()
```

matricula	sexo	Posgrado	folio
0718	1	MCSA	MCSA-0718-1
2183	2	MCEP	MCEP-2183-2
1241	1	MCSS	MCSS-1241-1
0213	2	MCSA	MCSA-0213-2
4386	2	MCBI	MCBI-4386-2

sep = “”

Permite agregar un separador entre los elementos a concatenar (por ejemplo, un guión)

1

001

Vector o variable a “inflar”

De qué lado se pone el texto que va a “inflar” (por defecto a la izquierda)

```
str_pad(string, width, side = c("left", "right", "both"), pad = " ")
```

Longitud que debe tener el texto

Texto con el que se va a “inflar”

```
malla %>%
  mutate(clave_mun = str_pad(mun, 3, pad = "0"))
```

mun	municipio	clave_mun
1	San Juan	001
72	Santa María	072
348	Guadalupe	348
9	San Pablo	009

Concatenar c() y str_pad()

```
malla %>%
   mutate(folio = str_c(id, nombre))
```

id	nombre	folio
1	Juan	1Juan
2	Pedro	2Pedro
3	Felipe	3Felipe

```
malla %>%
   mutate(folio = str_c(id, nombre, sep = "-"))
```

id	nombre	folio
1	Juan	1-Juan
2	Pedro	2-Pedro
3	Felipe	3-Felipe

```
malla %>%
   mutate(folio = str_c(str_pad(id, 2, pad = "0"),
                        nombre,
                        sep = "-"))
```

id	nombre	folio
1	Juan	01-Juan
2	Pedro	02-Pedro
3	Felipe	03-Felipe

str_sub(texto, start = 1, end = 4)

```
malla %>%
  mutate(posgrado = str_sub(folio,
                            start = 1,
                            end = 4)) %>%
  print()
```

matricula	sexo	folio	posgrado
0718	1	MCSA-0718-1	MCSA
2183	2	MCEP-2183-2	MCEP
1241	1	MCSS-1241-1	MCSS
0213	2	MCSA-0213-2	MCSA
4386	2	MCBI-4386-2	MCBI

str_sub

Permite extraer texto de un vector.

start =

En el ejemplo, el número 1 indica que se iniciará a extraer el texto a partir del primer carácter.

end =

En el ejemplo, el número 4 indica que se finalizará la extracción de texto en el cuarto carácter.

str_sub(texto, start = 5L)

```
malla %>%
  mutate(matri_sexo = str_sub(folio,
                              start = 6)) %>%
  print()
```

matricula	sexo	folio	matri_sexo
0718	1	MCSA-0718-1	0718-1
2183	2	MCEP-2183-2	2183-2
1241	1	MCSS-1241-1	1241-1
0213	2	MCSA-0213-2	0213-2
4386	2	MCBI-4386-2	4386-2

str_sub

Permite extraer texto de un vector.

start =

En el ejemplo, el número 5 indica que se iniciará a extraer el texto a partir del quinto carácter.

end =

Si no se indica este argumento entonces el texto restante a partir del carácter de inicio es seleccionado.


```
sun <- read_csv("./data/Base_SUN_2018.csv") %>% clean_names() %>% print()
```

```
Rows: 1089 Columns: 9

── Column specification ────────────────────────────────────────────────────────
Delimiter: ","
chr (8): CVE_ENT, NOM_ENT, CVE_MUN, NOM_MUN, CVE_LOC, NOM_LOC, CVE_SUN, NOM_SUN
dbl (1): POB_2018

ℹ Use `spec()` to retrieve the full column specification for this data.
ℹ Specify the column types or set `show_col_types = FALSE` to quiet this message.
# A tibble: 1,089 × 9
   cve_ent nom_ent             cve_mun nom_mun              cve_loc nom_loc cve_sun nom_sun     pob_2018
   <chr>   <chr>               <chr>   <chr>                <chr>   <chr>   <chr>   <chr>          <dbl>
 1 01      Aguascalientes      01011   "San Francisco de …  NA      NA      M01.01  Aguascalie…    42531
 2 01      Aguascalientes      01005   "Jes\xfas Mar\xeda"  NA      NA      M01.01  Aguascalie…   116700
 3 01      Aguascalientes      01001   "Aguascalientes"     NA      NA      M01.01  Aguascalie…   897331
 4 02      Baja California     02005   "Playas de Rosarit…  NA      NA      M02.03  Tijuana       110683
 5 02      Baja California     02003   "Tecate"             NA      NA      M02.03  Tijuana       115570
 6 02      Baja California     02004   "Tijuana"            NA      NA      M02.03  Tijuana      1798741
 7 02      Baja California     02002   "Mexicali"           NA      NA      M02.02  Mexicali     1065882
 8 02      Baja California     02001   "Ensenada"           NA      NA      M02.01  Ensenada      542896
 9 03      Baja California Sur 03003   "La Paz"             NA      NA      M03.01  La Paz        313204
10 04      Campeche            04002   "Campeche"           NA      NA      M04.01  Campeche      298741
# … with 1,079 more rows
```

Averiguamos la codificación que mejor se adapte a nuestra malla de datos

```
guess_encoding("./ruta/file.csv", n_max = 1000)
```

```
# A tibble: 2 × 2
  encoding   confidence
  <chr>           <dbl>
1 ISO-8859-1       0.36
2 ISO-8859-2       0.26
```

Importamos la malla con la codificación recomendada

```
read_csv("./ruta/file.csv", locale = readr::locale(encoding = "ISO-8859-1"))
```

```
# A tibble: 1,089 × 9
  cve_ent nom_ent          cve_mun nom_mun              cve_loc nom_loc cve_sun nom_sun      pob_2018
  <chr>   <chr>            <chr>   <chr>                <chr>   <chr>   <chr>   <chr>           <dbl>
1 01      Aguascalientes   01011   San Francisco de l… NA      NA      M01.01  Aguascalie…     42531
2 01      Aguascalientes   01005   Jesús María         NA      NA      M01.01  Aguascalie…    116700
3 01      Aguascalientes   01001   Aguascalientes      NA      NA      M01.01  Aguascalie…    897331
4 02      Baja California  02005   Playas de Rosarito  NA      NA      M02.03  Tijuana        110683
5 02      Baja California  02003   Tecate              NA      NA      M02.03  Tijuana        115570
```

Generar variables condicionales case_when( )

```
malla
```

nombre	edad
Luisa	27
Juana	31
Petra	28
María	41
Andrea	33

```
malla %>%
  mutate(edad_gpo = case_when(edad >= 20 & edad < 30 ~ "20 a 29",
                              edad >= 30 & edad < 40 ~ "30 a 39",
                              edad >= 40 ~ "40 y más")) %>%
  print()
```

nombre	edad	edad_gpo
Luisa	27	"20 a 29"
Juana	31	"30 a 39"
Petra	28	"20 a 29"
María	41	"40 y más"
Andrea	33	"30 a 39"

Generar variables condicionales case_when( )

```
malla
```

nombre	edad
Luisa	27
Juana	31
Petra	28
María	41
Andrea	33

```
malla %>%
  mutate(edad_gpo = case_when(edad >= 20 & edad < 30 ~ 2L,
                              edad >= 30 & edad < 40 ~ 3L,
                              edad >= 40 ~ 4L)) %>%
  print()
```

nombre	edad	edad_gpo
Luisa	27	2
Juana	31	3
Petra	28	2
María	41	4
Andrea	33	3

Generar variables condicionales case_when( )

Generar nueva columna

Columna con los valores a identificar

Condiciones
- mayor qué
- menor qué
- igual a

```
malla %>%
  mutate(new_var = case_when(variable == "condición_1" ~ "resultado",
                             variable == "condición_2" ~ "resultado",
                             TRUE ~ variable))
```

Valor de la condición
- número
- texto
- lógico

Valor a almacenar en la nueva variable

x < y	menor qué
x > y	mayor qué
x == y	igual a
x <= y	menor o igual a
x >= y	mayor o igual a
x != y	diferente de
x %in% y	pertenece a
is.na(x)	is NA
!is.na(x)	Distinto de NA

Recodificar valores

Activar paquete en la sesión

Comando para convertir valores a NA

Columna que contiene los valores NA

Genero columna, si ya existe entonces la sobreescribe.

```
library(fauxnaif)
malla %>%
  mutate(sexo = na_if_in(sexo, 98, 99),
         edad = na_if_in(edad, -88, -99),
         peso = na_if_in(peso, -88, -99)) %>%
  print()
```

Valores a convertir a NA

```
malla
```

nombre	sexo	edad	peso
Kevin	1	17	-99
Brayan	1	-99	61.7
Kimberly	98	15	51.9
Britany	2	16	59.3
Brandon	99	17	-88
Melany	2	-88	61.6

nombre	sexo	edad	peso
Kevin	1	17	NA
Brayan	1	NA	61.7
Kimberly	NA	15	51.9
Britany	2	16	59.3
Brandon	NA	17	NA
Melany	2	NA	61.6

Recodificar valores

Es posible hacer todo el proceso para varias columnas a la vez

```
malla
```

nombre	sexo	edad	peso
Kevin	1	17	-99
Brayan	1	-99	61.7
Kimberly	98	15	51.9
Britany	2	16	59.3
Brandon	99	17	-88
Melany	2	-88	61.6

```
library(fauxnaif)
malla %>%
  mutate(across(c(sexo:peso), na_if_in, -88, -99, 98, 99)) %>%
  print()
```

nombre	sexo	edad	peso
Kevin	1	17	NA
Brayan	1	NA	61.7
Kimberly	NA	15	51.9
Britany	2	16	59.3
Brandon	NA	17	NA
Melany	2	NA	61.6

Trabajar con NA

nombre	edad	peso	pelo
juan	18	68.3	lacio
eva	NA	70.1	NA
luis	19	69.4	lacio
ana	20	NA	lacio
mario	20	73.5	chino
edith	19	65.2	NA
david	21	76.4	NA

```
malla %>% drop_na()
malla %>% na_omit()
```

nombre	edad	peso	pelo
juan	18	68.3	lacio
luis	19	69.4	lacio
mario	20	73.5	chino

Trabajar con NA

nombre	edad	peso	pelo
juan	18	68.3	lacio
eva	NA	70.1	NA
luis	19	69.4	lacio
ana	20	NA	lacio
mario	20	73.5	chino
edith	19	65.2	NA
david	21	76.4	NA

```
malla %>% drop_na(pelo)
```

nombre	edad	peso	pelo
juan	18	68.3	lacio
luis	19	69.4	lacio
ana	20	NA	lacio
mario	20	73.5	chino

Trabajar con NA

nombre	edad	peso	pelo
juan	18	68.3	lacio
eva	NA	70.1	NA
luis	19	69.4	lacio
ana	20	NA	lacio
mario	20	73.5	chino
edith	19	65.2	NA
david	21	76.4	NA

```
malla %>% drop_na(edad, peso)
```

nombre	edad	peso	pelo
juan	18	68.3	lacio
luis	19	69.4	lacio
mario	20	73.5	chino
edith	19	65.2	NA
david	21	76.4	NA

Su turno...

Realice las siguientes actividades a partir de la malla pm25

- Genere columna month de forma numérica {lubridate}
- Genere variable pm25_lim en la que clasifique la concentración de $PM_{2.5}$ de acuerdo a si cumple la NOM o la guía OMS
  - Valor NOM (¿? µg/m^3): "incumple NOM"
  - Valor OMS (¿? µg/m^3): "incumple OMS"
  - Valor cumple valores límites: "Aceptable"
- Guarde el resultado en objeto de nombre pm25_dia

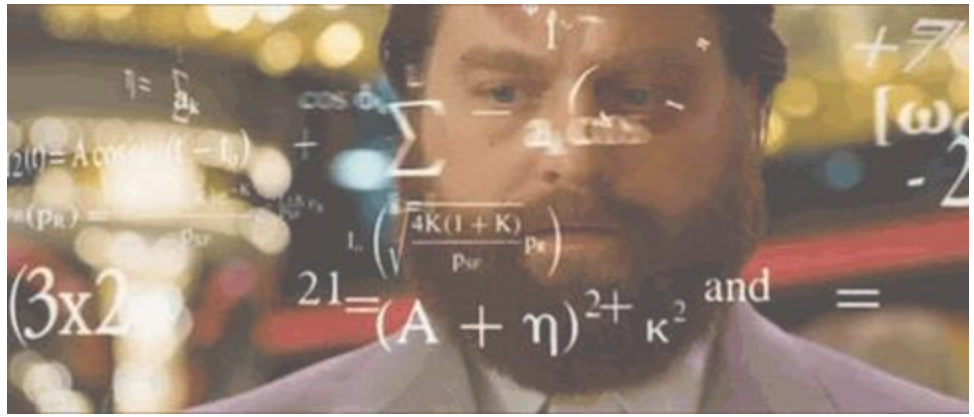

```
ggplot(data = pm25_dia) +
  geom_point(aes(date, pm25, colour = pm25_lim)) +
  theme_light()
  theme(legend.position = "bottom")
```

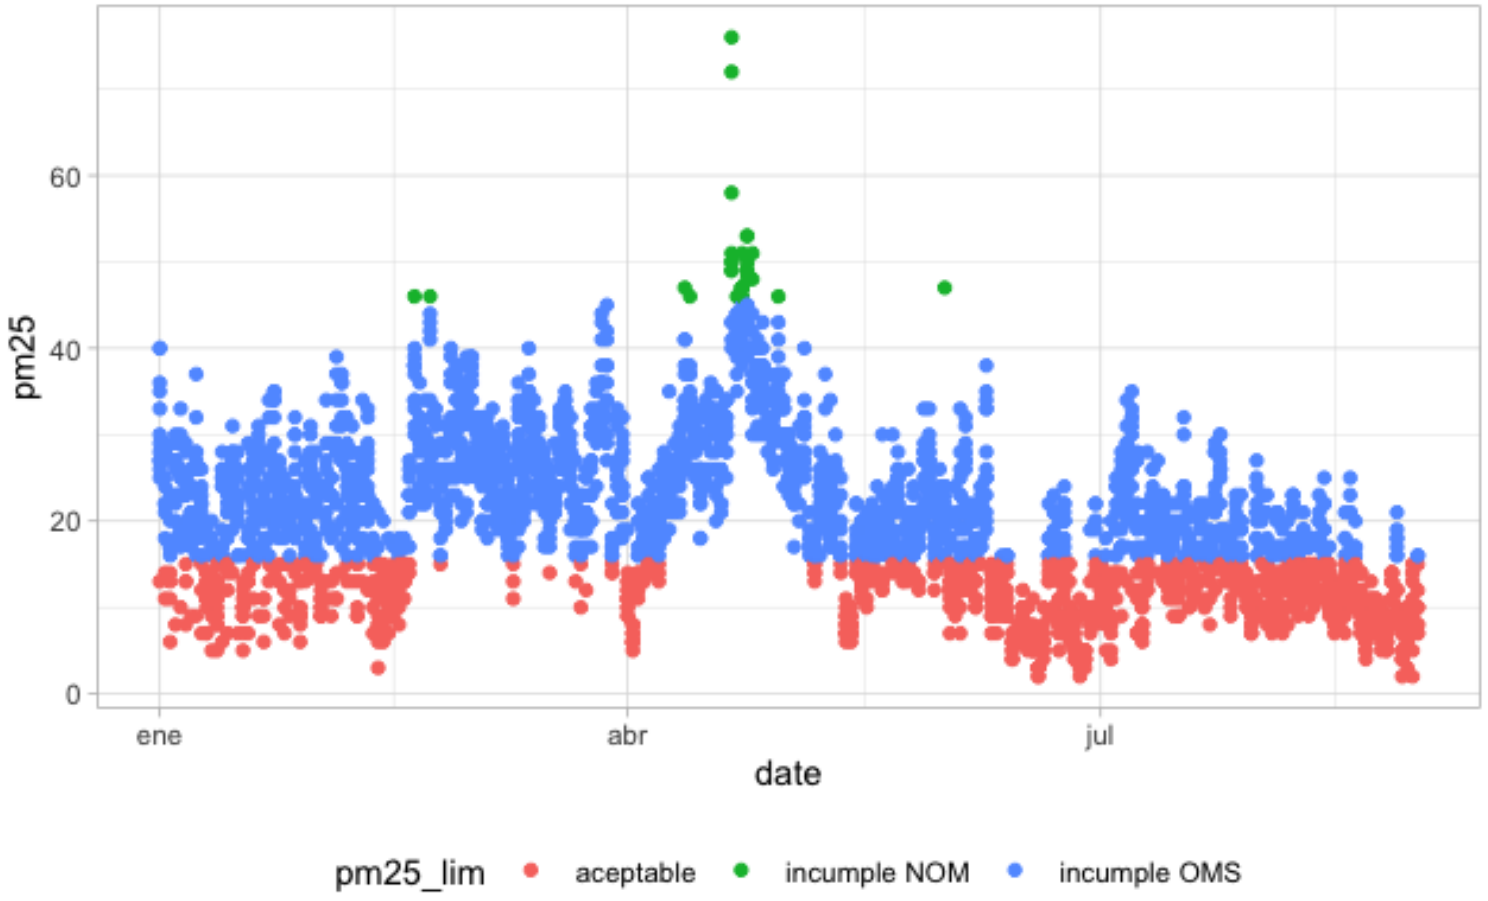

```
ggplot(data = pm25_dia) +
  geom_point(aes(date, pm25, colour = pm25_lim)) +
  theme_light()
  theme(legend.position = "bottom")
```